

Các phương pháp học máy kết hợp

Boosting, Bagging, và Random Forests

Nguyễn Thanh Tùng

Khoa Công nghệ thông tin – Đại học Thủy Lợi

tungnt@tlu.edu.vn

Website môn học: <https://sites.google.com/a/wru.vn/cse445fall2016>

Bài giảng có sử dụng hình vẽ trong cuốn sách “An Introduction to Statistical Learning with Applications in R” với sự cho phép của tác giả, có sử dụng slides các khóa học CME250 của ĐH Stanford và IOM530 của ĐH Southern California



Bootstrap là gì?





- Giả sử ta có 5 quả bóng gắn nhãn A,B,C,D, E và bỏ tất cả chúng vào trong 1 cái giỏ.
- Lấy ra ngẫu nhiên 1 quả từ giỏ và ghi lại nhãn, sau đó bỏ lại quả bóng vừa bốc được vào giỏ.
- Tiếp tục lấy ra ngẫu nhiên một quả bóng và lặp lại quá trình trên cho đến khi việc lấy mẫu kết thúc. Việc lấy mẫu này gọi là lấy mẫu có hoàn lại.
- Kết quả của việc lấy mẫu như trên có thể như sau (giả sử kích thước mẫu là 10):

C, D, E, E, A, B, C, B, A, E



Bootstrap là gì?

- Bootstrap là phương pháp lấy mẫu có hoàn lại (sampling with replacement) -> một mẫu có thể xuất hiện nhiều lần trong một lần lấy mẫu



Bootstrap là gì?

- Là kỹ thuật rất quan trọng trong thống kê
- Lấy mẫu có hoàn lại từ tập dữ liệu ban đầu để tạo ra các tập dữ liệu mới




Các phương pháp kết hợp

Ensemble Methods



Sức mạnh của các bộ phân lớp yếu

Condorcet's Jury Theorem — Nếu p lớn hơn $1/2$ (mỗi cử tri bỏ phiếu đúng mong muốn của họ), càng thêm nhiều cử tri sẽ tăng xác suất theo quyết định số đông sẽ chính xác. Trong giới hạn, xác suất bầu chọn theo số đông tiến đến 1 khi số cử tri tăng lên.



Source: gallica.bnf.fr / Bibliothèque nationale de France



Sức mạnh của các bộ phân lớp yếu

Condorcet's Jury Theorem — Nếu p lớn hơn $1/2$ (mỗi cử tri bỏ phiếu đúng mong muốn của họ), càng thêm nhiều cử tri sẽ tăng xác suất theo quyết định số đông sẽ chính xác. Trong giới hạn, xác suất bầu chọn theo số đông tiến đến 1 khi số cử tri tăng lên.



Sức mạnh của các bộ phân lớp yếu

- Việc lấy trung bình làm giảm phương sai và không làm tăng bias (bias vẫn được giữ nguyên) $\text{Var}[\bar{Y}] = \sigma^2/n$



Sức mạnh của các bộ phân lớp yếu

- Việc lấy trung bình làm giảm phương sai và không làm tăng bias (bias vẫn được giữ nguyên) $\text{Var}[\bar{Y}] = \sigma^2/n$
- Các phiếu bầu của các bộ phân lớp tương quan không trợ giúp được nhiều

THE CHOICE OF A CANDIDATE

THE NEW YORK TIMES supported Franklin D. Roosevelt for the Presidency in 1932 and again in 1936. In 1940 it will support Wendell Willkie.



Sức mạnh của các bộ phân lớp yếu

- Việc lấy trung bình làm giảm phương sai và không làm tăng bias (bias vẫn được giữ nguyên) $\text{Var}[\bar{Y}] = \sigma^2/n$
- Các phiếu bầu của các bộ phân lớp tương quan không trợ giúp được nhiều $\text{Var}[\bar{Y}] = \sigma^2/n + (\rho\sigma^2)(n-1)/n$

THE CHOICE OF A CANDIDATE

THE NEW YORK TIMES supported Franklin D. Roosevelt for the Presidency in 1932 and again in 1936. In 1940 it will support Wendell Willkie.



Kết hợp các bộ phân lớp

$$\alpha \times \{CART\} + (1 - \alpha) \times \{LinearModel\}$$




Các phương pháp kết hợp: Bagging



Bagging là gì?

“Bootstrap Aggregation”



Bagging là gì?


“Bootstrap Aggregation”

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$$




Bagging


Giải quyết được tính thiếu ổn định của CART



+




+



Bagging


- Lấy mẫu tập dữ liệu huấn luyện theo Bootstrap để tạo ra tập hợp các dự đoán.



Bagging

- Lấy mẫu tập dữ liệu huấn luyện theo Bootstrap để tạo ra tập hợp các dự đoán.

Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.



- Lấy trung bình (hoặc bình chọn theo số đông- majority vote) các bộ dự đoán độc lập.
- Bagging giảm phương sai (variance) và giữ bias.



Bagging





FIGURE 8.9. Bagging trees on simulated dataset. The top left panel shows the original tree. Eleven trees grown on bootstrap samples are shown. For each tree, the top split is annotated.



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.



Bagging

Original Data	1	2	3	4	5	6	7	8	9	10
Bagging (Round 1)	7	8	10	8	2	5	10	10	5	9
Bagging (Round 2)	1	4	9	1	2	3	2	7	3	2
Bagging (Round 3)	1	8	5	10	5	5	9	6	3	7

- Lấy mẫu có hoàn lại
- Xây dựng bộ phân lớp trên mỗi mẫu bootstrap
- Mỗi mẫu bootstrap chứa xấp xỉ 63.2% số lượng mẫu trong tập dữ liệu ban đầu
- Số lượng mẫu còn lại (36.8%) được dùng để kiểm thử



Bagging

Model 1		7/10 correct
Model 2		7/10 correct
Model 3		6/10 correct
Ensemble Model (Majority Voting)		

For more tutorials: algotutorials.com




Bonus! Out-of-bag cross-validation



Các mẫu Out-of-bag (OOB)

- Quá trình Bootstrapping:




- Mỗi cây chỉ sử dụng một tập con các mẫu huấn luyện (trung bình số mẫu $\sim 2/3$).
- Số mẫu cho OOB khoảng $\sim 1/3$ của cây quyết định.



Dự đoán mẫu OOB

- Với mỗi mẫu, tìm các cây mà nó là OOB.



- Dự đoán giá trị của chúng từ các cây này.
- Ước lượng lỗi dự đoán của cây (bagged trees) dùng tất cả các dự đoán OOB.
- Tương tự như kỹ thuật kiểm tra chéo (cross-validation).



Các phương pháp kết hợp: Boosting




Boosting là gì?

- Boosting là kỹ thuật mới nâng cao hiệu suất của mô hình phân lớp
- Các thí nghiệm cho thấy boosting có thể tăng thêm độ chính xác của mô hình phân lớp lên 15%
- Tất cả các mô hình phân lớp học có giám sát đều có thể dùng kỹ thuật boosting để nâng cao độ chính xác



Boosting là gì?

- Boosting xây dựng bộ phân loại kết hợp với các mẫu huấn luyện có trọng số khác nhau. Sau mỗi bước lặp, các mẫu huấn luyện bị dự đoán sai sẽ được đánh trọng số tăng lên, các mẫu đã dự đoán đúng sẽ được đánh trọng số nhỏ hơn
- Điều này giúp cho Boosting tập trung vào cải thiện độ chính xác cho các mẫu bị dự đoán sai sau mỗi bước lặp



$$\hat{f}(x) \leftarrow \hat{f}(x) + \lambda \hat{f}^b(x) \quad \text{Độ quan trọng của tỷ lệ lỗi học, } \lambda.$$



Boosting

AdaBoost with trees has been called the
“best off-the-shelf classifier in the world”
-Leo Breiman



Boosting

Tham số đầu vào,

λ “learning rate”


B # of trees

d “interaction depth”




Boosting vs. Bagging

Bagged Decision Rule



Boosted Decision Rule



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.



Câu hỏi?



Phương pháp Rừng ngẫu nhiên Random Forests (RF)




Động lực để có Random forest

- Mô hình dựa trên cây phân loại và hồi quy (CART).
- Các mô hình cây có lỗi bias thấp, tuy nhiên phương sai lại cao (high variance).
- Phương pháp Bagging dùng để giảm phương sai.



Nhắc lại: Bagging

- Lấy mẫu tập dữ liệu huấn luyện theo Bootstrap để tạo ra tập hợp các dự đoán.



- Lấy trung bình (hoặc bình chọn theo số đông-majority vote) các bộ dự đoán độc lập.
- Bagging giảm phương sai (variance) và giữ bias.



Bagged trees vs. random forests


- Phương pháp Bagging biểu thị sự biến thiên (variability) giữa các cây bởi việc chọn mẫu ngẫu nhiên từ dữ liệu huấn luyện.
- Cây được sinh ra từ phương pháp Bagging vẫn có tương quan lẫn nhau, do đó hạn chế trong việc giảm phương sai.

Random forests đưa ra thêm tính ngẫu nhiên (randomness):


- Làm giảm mối tương quan giữa các cây bằng cách lấy ngẫu nhiên các biến khi tách nút của cây.



Các biến dùng cho tách nút




Các biến dùng cho tách nút



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.



Rừng ngẫu nhiên



Introduction to Data Mining – Tan, Steinbach, Kumar



Rừng ngẫu nhiên



For more tutorials: sigobbeans.com



Các tham số chính

Các tham số quan trọng của Rừng ngẫu nhiên:

- Số lượng biến khả tách tại mỗi nút (m)
- Độ sâu của từng cây trong rừng (số lượng mẫu tối thiểu tại mỗi nút của cây-minimum node size)
- Số lượng cây trong rừng



Số lượng biến khả tách

Giá trị mặc định

Bài toán phân lớp $m = \lfloor \sqrt{p} \rfloor$


Bài toán hồi quy $m = \lfloor p/3 \rfloor$

gói randomForest trong R dùng *mtry*



Độ sâu của từng cây

(số lượng mẫu tối thiểu tại mỗi nút của cây)



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.




Độ sâu của cây

	Giá trị mặc định
Bài toán phân lớp	1
Bài toán hồi quy	5



Số lượng cây trong rừng



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.

- Thêm nhiều cây không gây ra overfitting.



Các tính năng khác của RF


- Các mẫu Out-of-bag (OOB)
- Độ quan trọng của biến (Variable importance measurements)



Độ quan trọng của biến

Dạng 1:


Độ giảm của lỗi dự đoán hoặc impurity từ các điểm tách nút liên quan đến các biến đó, cuối cùng lấy trung bình trên các cây trong rừng.



Độ quan trọng của biến


Dạng 2:

Độ tăng lỗi dự đoán tổng thể khi các giá trị của biến được hoán vị ngẫu nhiên giữa các mẫu.



Ví dụ về độ quan trọng của biến

- Cả 2 dạng biểu thị gần giống nhau, tuy nhiên có sự khác biệt về xếp hạng các biến:



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.




Ưu điểm của RF

Tương tự như CART:

- Tương đối mạnh trong việc xử lý biến rác (non-informative variable)
(Việc lựa chọn biến tích hợp sẵn khi xây dựng mô hình, built-in variable selection)



Ảnh hưởng của biến rác



Hastie, Trevor, et al. The elements of statistical learning. Vol. 2. No. 1. New York: Springer, 2009.



Ưu điểm của RF

Tương tự như CART:

- Tương đối mạnh trong việc xử lý biến rác (non-informative variable)
- Xử lý (nắm bắt) được độ tương tác bậc cao giữa các biến (Capture high-order interactions between variables)
- Có lỗi bias thấp
- Dễ xử lý các biến hỗn hợp (biến rời rạc, phân loại)



Ưu điểm của RF

Ưu điểm vượt trội CART:

- Lỗi phương sai thấp hơn (mạnh hơn vì sử dụng phương pháp bootstrapping lấy mẫu từ tập huấn luyện)
- Ít bị overfitting hơn
- Không cần tỉa cây (No need for pruning)
- Kiểm tra chéo được tích hợp sẵn trong mô hình (dùng các mẫu OOB)



Nhược điểm của RF

Tương tự như CART:

- Khó nắm bắt độ cộng tính

Nhược điểm so với CART:

- Khó diễn giải/giải thích mô hình dự đoán



Câu hỏi?

